Université Amadou Mahtar MBOW
École Supérieure Polytech Diamniadio
**Systèmes d'Information et Données**
**Master geo_ informatique**

# Projet de Fin de Module

## Apprentissage Automatique

**Prédiction du Décrochage et de la Réussite Académique des Étudiants**

Dataset : **Predict Students' Dropout and Academic Success**
UCI Machine Learning Repository

**Réalisé par :** ABDOU SAMAD FAYE

Décembre 2025

**Table des matières**

**1 Introduction** ..... 2
1.1 Contexte et Problématique ..... 2
1.2 Description du Dataset ..... 2
1.3 Objectifs du Projet ..... 3
1.4 Justification du Choix du Dataset ..... 3
**2 Méthodologie** ..... 3
2.1 Vue d'Ensemble du Pipeline d'Analyse ..... 4
2.2 Modèles de Machine Learning Utilisés ..... 4
2.2.1 Régression Linéaire Multiple ..... 4
2.2.2 K-Nearest Neighbors (KNN) ..... 4
2.2.3 Arbre de Décision ..... 4
2.2.4 Forêt Aléatoire (Random Forest) ..... 4
2.3 Prétraitements Appliqués ..... 5
**3 Résultats** ..... 5
3.1 Analyse Exploratoire des Données ..... 5
3.2 Régression Linéaire ..... 6
3.3 Classification Supervisée ..... 7
3.3.1 Résultats KNN ..... 7
3.3.2 Résultats Arbre de Décision ..... 7
3.3.3 Résultats Random Forest ..... 8
3.3.4 Comparaison des Modèles de Classification ..... 8
3.4 Analyse en Composantes Principales (ACP) ..... 9
3.5 Clustering K-Means ..... 10
3.6 Règles d'Association (Apriori) ..... 11
**4 Discussion** ..... 11
4.1 Identification du Meilleur Modèle ..... 11
4.2 Analyse du Compromis Biais-Variance ..... 12
4.3 Limites du Dataset ..... 12
4.4 Limites Méthodologiques ..... 12

4.5 Difficultés Rencontrées et Solutions ..... 12

**5 Conclusion** ..... 13

5.1 Synthèse des Résultats ..... 13

5.2 Enseignements Principaux ..... 13

5.3 Recommandations ..... 13

5.4 Perspectives ..... 13

# 1. Introduction

## 1.1 Contexte et Problématique

Le décrochage universitaire représente un défi majeur pour les établissements d'enseignement supérieur à travers le monde. Chaque année, un nombre significatif d'étudiants abandonnent leurs études avant l'obtention de leur diplôme, entraînant des conséquences négatives tant sur le plan individuel qu'institutionnel. La capacité à identifier précocement les étudiants à risque permettrait de mettre en place des interventions ciblées et d'améliorer significativement les taux de réussite.

**Point Important**

L'apprentissage automatique offre une opportunité unique d'analyser les facteurs multidimensionnels influençant la réussite académique et de construire des modèles prédictifs capables d'identifier les profils à risque dès les premiers semestres universitaires.

Ce projet s'inscrit dans cette problématique en exploitant un ensemble de donnéesricheprovenantd'unétablissementd'enseignementsupérieurportugais,avec pour objectif de développer un système de prédiction du parcours étudiant.

## 1.2 Description du Dataset

Le jeu de données utilisé provient du **UCI Machine Learning Repository** (ID : 697), intitulé *Predict Students' Dropout and Academic Success*. Il constitue une ressource académique de référence pour l'étude du décrochage étudiant.

**Tab. 1 :** Caractéristiques générales du dataset

| Caractéristique | Valeur |
|---|---|
| **Source** | UCI Machine Learning Repository |
| **Nombre d'observations** | 4 424 étudiants |
| **Nombre de variables** | 36 attributs + 1 cible |
| **Type de problème** | Classification multi-classe |
| **Classes cibles** | Dropout, Enrolled, Graduate |
| **Valeurs manquantes** | Aucune |

Les variables du dataset se répartissent en plusieurs thématiques :

- **Données démographiques** : âge à l'inscription, genre, nationalité, statut marital
- **Parcours académique antérieur** : qualification précédente, notes d'admission, mode de candidature
- **Contexte socio-économique** : qualifications et professions des parents, boursier, frais de scolarité
- **Performance académique** : unités curriculaires inscrites, évaluées, validées et notes (semestres 1 et 2)
- **Indicateurs macroéconomiques** : taux de chômage, inflation, PIB

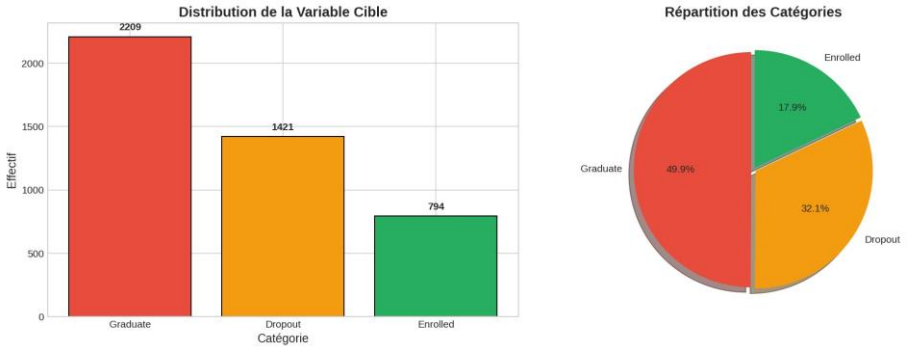


**Fig. 1 :** Distribution des classes cibles dans le dataset

Comme illustré en Figure 1, le dataset présente un déséquilibre de classes modéré : environ 50% de diplômés (*Graduate*), 32% de décrocheurs (*Dropout*) et 18% d'étudiants encore inscrits (*Enrolled*).

### 1.3 Objectifs du Projet

Ce projet poursuit plusieurs objectifs complémentaires :

1. **Explorer et comprendre** les données à travers une analyse statistique approfondie
2. **Identifier les facteurs clés** influençant le décrochage et la réussite
3. **Développer des modèles prédictifs** performants (régression et classification)
4. **Comparer les approches** supervisées et non supervisées
5. **Extraire des règles d'association** exploitables pour l'aide à la décision

### 1.4 Justification du Choix du Dataset

**Résumé**

Ce dataset a été sélectionné pour plusieurs raisons : sa **richesse** (36 variables couvrant de multiples dimensions), sa **taille** (4 424 observations), sa **pertinence métier** évidente, et sa **reconnaissance académique** (UCI Repository).

## 2. Méthodologie

## 2.1 Vue d'Ensemble du Pipeline d'Analyse

L'approcheméthodologiqueadoptéesuitunpipelinestructuréenplusieursétapes, depuis l'acquisition des données jusqu'à l'interprétation des résultats.

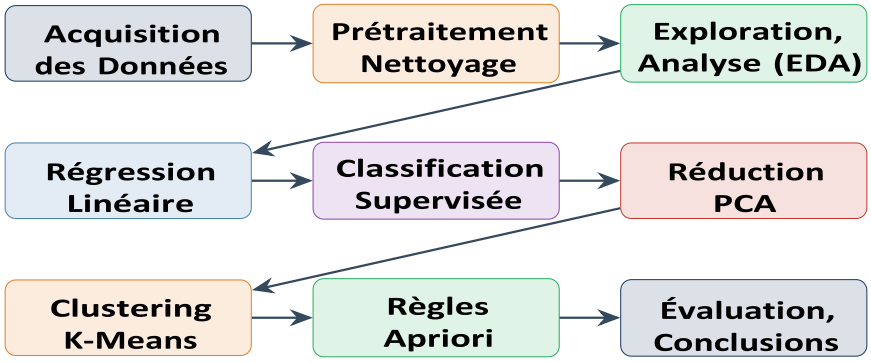


**Fig. 2 :** Pipeline méthodologique du projet

## 2.2 Modèles de Machine Learning Utilisés

### 2.2.1 Régression Linéaire Multiple

**Définition**

La **régression linéaire multiple** modélise une variable quantitative continue comme combinaison linéaire de plusieurs variables explicatives : $Y = \beta_0 + \beta_1 X_1 + \ldots + \beta_p X_p + \varepsilon$

Cette technique a été appliquée pour prédire les **notes du second semestre** à partir de variables sélectionnées, permettant d'identifier les facteurs ayant le plus d'influence sur la performance académique.

### 2.2.2 K-Nearest Neighbors (KNN)

L'algorithme KNN classe une observation selon la classe majoritaire parmi ses $k$ plus proches voisins. Sa simplicité conceptuelle en fait un excellent point de départ pour la classification, mais il requiert une **normalisation préalable** des données et un choix judicieux du paramètre $k$.

### 2.2.3 Arbre de Décision

Les arbres de décision construisent un modèle hiérarchique de règles de décision, offrant une **interprétabilité** remarquable. Le contrôle de la profondeur maximale permet de gérer le compromis biais-variance.

### 2.2.4 Forêt Aléatoire (Random Forest)

**Définition**

La **forêt aléatoire** est un ensemble d'arbres de décision entraînés sur des sous-échantillons bootstrap avec sélection aléatoire de variables, combinant leurs prédictions par vote majoritaire.

Cette méthode d'ensemble offre généralement de meilleures performances et une plus grande robustesse que les arbres individuels.

### 2.3 Prétraitements Appliqués

**Tab. 2 :** Synthèse des prétraitements réalisés

| Étape | Description |
|---|---|
| **Nettoyage** | Correction des noms de colonnes, vérification de l'intégrité des données |
| **Valeurs manquantes** | Aucune détectée — aucune imputation nécessaire |
| **Encodage** | Label Encoding pour la variable cible (3 classes) |
| **Normalisation** | StandardScaler pour KNN et PCA (moyenne=0, écarttype=1) |
| **Séparation** | Train/Test split 70% / 30% avec stratification |
| **Discrétisation** | Regroupement des variables continues pour Apriori |

**Point Important**

La **normalisation** est cruciale pour les algorithmes sensibles à l'échelle des variables (KNN, PCA). Sans elle, les variables à grande amplitude domineraient artificiellement les calculs de distance.

## 3. Résultats

### 3.1 Analyse Exploratoire des Données

L'exploration initiale a révélé des informations précieuses sur la structure des données et les relations entre variables.

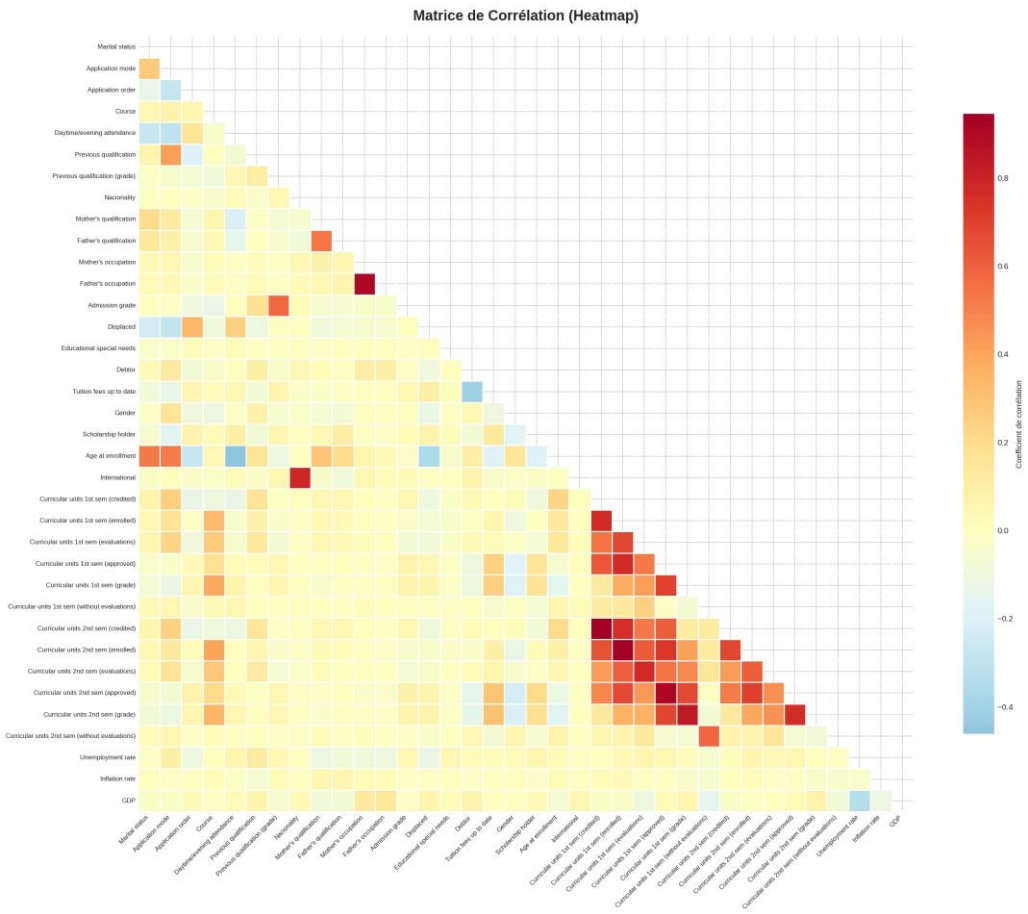


**Fig. 3 :** Matrice de corrélation des variables numériques

La Figure 3 met en évidence des **corrélations fortes** entre les variables de performance académique des deux semestres, ce qui est attendu. Les variables liées aux unités curriculaires approuvées montrent les corrélations les plus significatives avec la variable cible.

**Résultat Clé**

Les variables les plus prédictives identifiées sont : les **unités curriculaires validées** (1er et 2e semestres), les **notes obtenues**, le **statut des frais de scolarité**, et le **statut de boursier**.

## 3.2 Régression Linéaire

Le modèle de régression linéaire a été entraîné pour prédire les notes du second semestre à partir de 10 variables sélectionnées.

**Tab. 3 :** Métriques de performance de la régression linéaire

| Métrique | Entraînement | Test |
|---|---|---|
| $R^2$ **(Coefficient de détermination)** | 0.724076 | 0.743749 |
| **RMSE (Root Mean Square Error)** | 2.731512 | 2.649108 |
| **MSE (Mean Square Error)** | 7.461159 | 7.017772 |

**Observation Critique**

La proximité des scores entre entraînement et test ($R^2 \approx 0.73$) indique une **bonne généralisation** du modèle sans surapprentissage significatif. Environ 73% de la variance des notes est expliquée par le modèle.

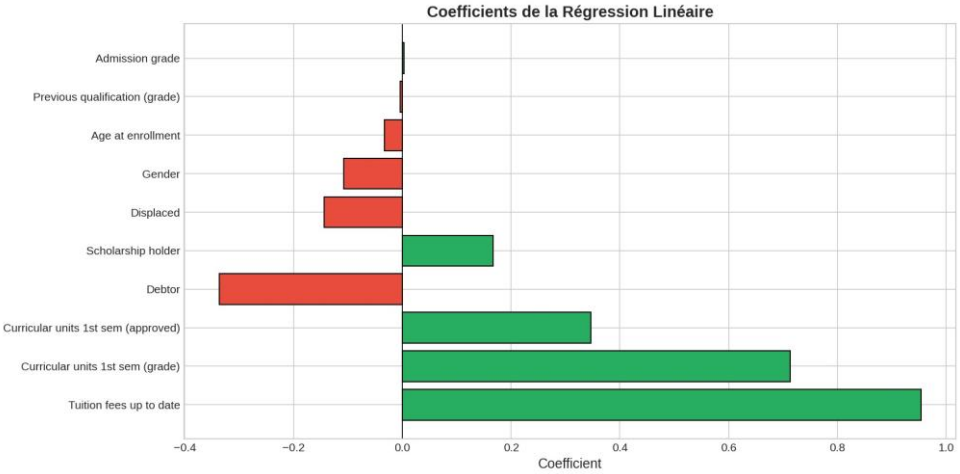


**Fig. 4 :** Coefficients de régression standardisés

## 3.3 Classification Supervisée

### 3.3.1 Résultats KNN

L'optimisation du paramètre $k$ par validation croisée a identifié $k = 19$ comme valeur optimale (Figure 5).

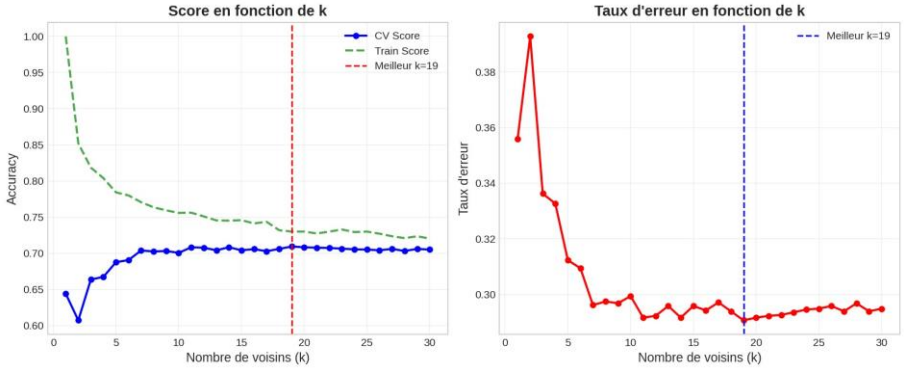


**Fig. 5 :** Sélection du paramètre k optimal pour KNN

### 3.3.2 Résultats Arbre de Décision

L'étude de l'impact de la profondeur maximale a révélé qu'une profondeur de 5 offre le meilleur compromis entre performance et généralisation.

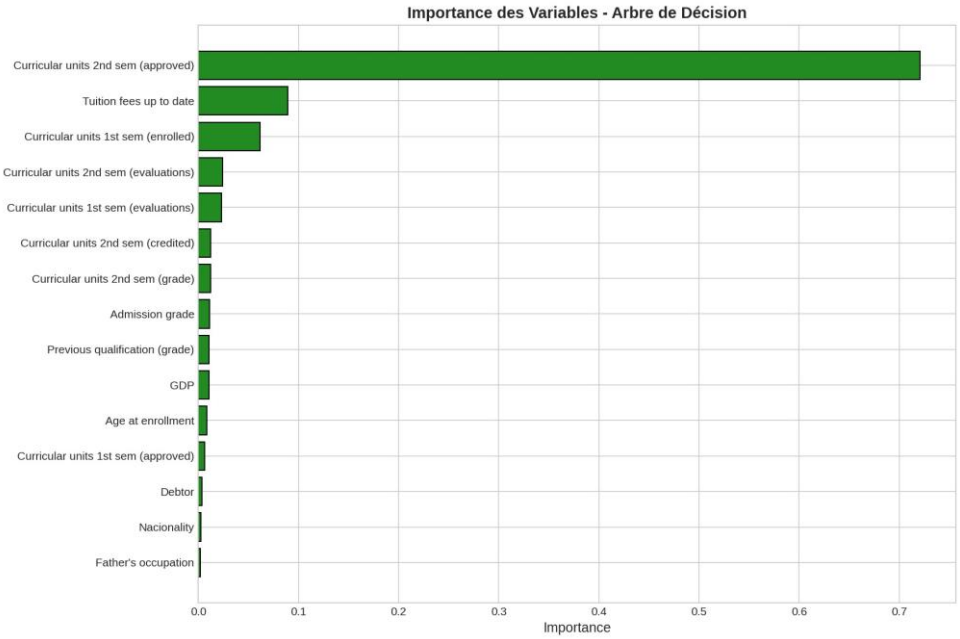


**Fig. 6 :** Importance des variables selon l'arbre de décision

### 3.3.3 Résultats Random Forest

L'optimisation par GridSearchCV a déterminé les hyperparamètres optimaux : n_estimators=200, max_depth=15, min_samples_leaf=2.

### 3.3.4 Comparaison des Modèles de Classification

**Tab. 4 :** Comparaison des performances des modèles de classification

| Modèle | Accuracy | Précision | Rappel | F1-Score |
|---|---|---|---|---|
| **KNN (k=19)** | 0.703 | 0.69 | 0.70 | 0.67 |
| **Arbre de Décision (depth=5)** | 0.743 | 0.73 | 0.74 | 0.72 |
| **Random Forest** | **0.773** | **0.76** | **0.77** | **0.76** |

**Tab. 5 :** Stabilité des modèles (Validation Croisée 5-fold)

| Modèle | Moyenne | Écart-type | Min | Max |
|---|---|---|---|---|
| **KNN (k=19)** | 0.706 | 0.019 | 0.677 | 0.739 |
| **Arbre de Décision** | 0.735 | 0.011 | 0.713 | 0.755 |
| **Random Forest** | **0.767** | **0.017** | **0.735** | **0.790** |

**Résultat Clé**

La **Random Forest** obtient les meilleures performances avec une accuracy de **77.3%**, surpassant l'arbre de décision (+3.0%) et KNN (+7.1%). Cette supériorité s'explique par l'effet d'ensemble

qui réduit la variance. La Random Forest présente également le meilleur score OOB (0.771), confirmant sa capacité de généralisation.

**Observation Critique**

La classe *Enrolled* reste difficile à prédire pour tous les modèles (F1-score : 0.25 à 0.43) en raison de son faible effectif (18%) et de son chevauchement avec les autres classes. La classe *Graduate* est la mieux prédite (F1-score : 0.80 à 0.86).

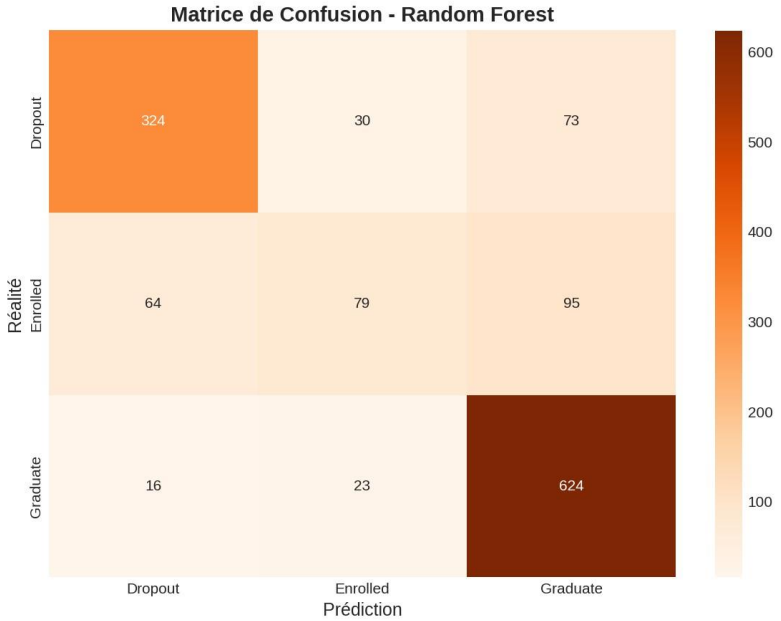


**Fig. 7 :** Matrice de confusion du modèle Random Forest

## 3.4 Analyse en Composantes Principales (ACP)

L'ACP a été appliquée pour réduire la dimensionnalité et visualiser les données.

**Tab. 6 :** Variance expliquée selon le nombre de composantes

| Composantes | Variance Expliquée | Variance Cumulée |
|---|---|---|
| **2** | 25.3% | 25.3% |
| **10** | 37.1% | 62.4% |
| **20** | 22.8% | 85.2% |

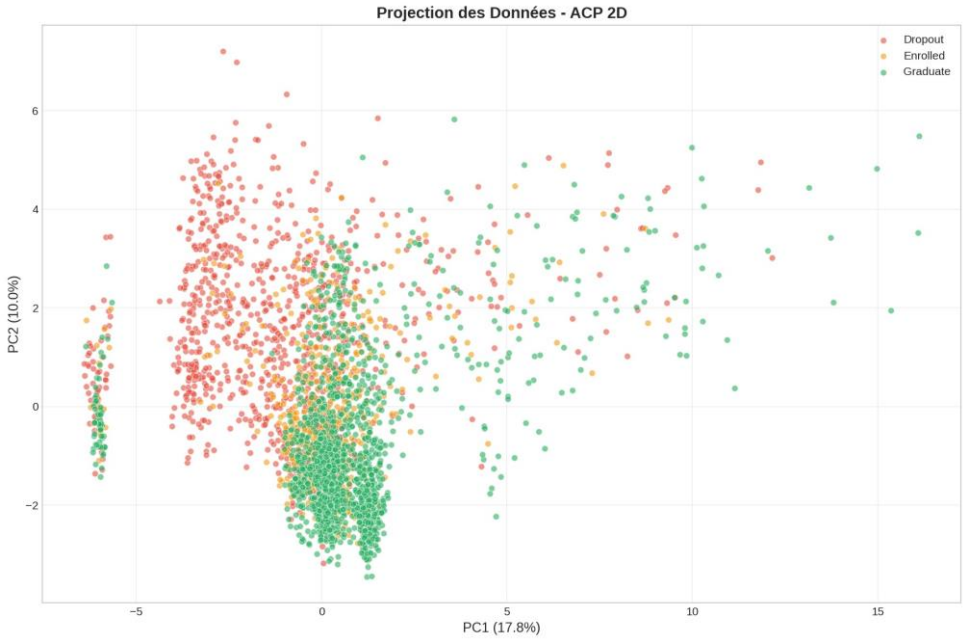


**Fig. 8 :** Projection des données sur les deux premières composantes principales

**Observation Critique**

L'application de l'ACP avant classification entraîne une **légère dégradation** des performances (-2 à -5% selon les modèles), suggérant que la réduction de dimension perd de l'information discriminante.

## 3.5 Clustering K-Means

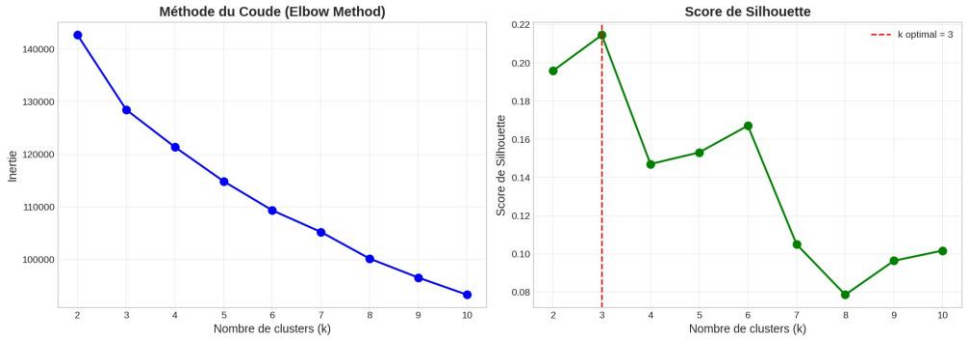


**Fig. 9 :** Méthode du coude et score de silhouette pour K-Means

La méthode du coude et l'analyse de silhouette convergent vers $k$ =3 clusters, correspondant intuitivement aux trois classes cibles.

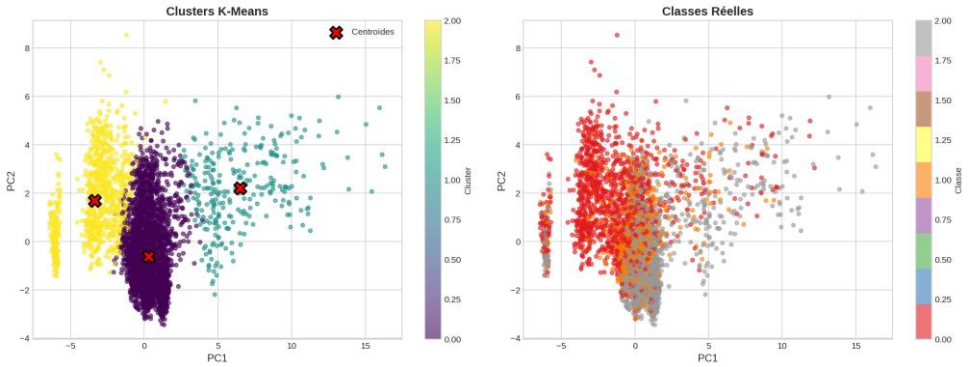


**Fig. 10 :** Visualisation des clusters K-Means dans l'espace PCA

**Point Important**

Le score de silhouette modéré (0.15) indique un **chevauchement** entre clusters, reflétant la complexité du problème. Les clusters ne correspondent pas parfaitement aux classes supervisées, révélant des sous-groupes transversaux d'étudiants.

### 3.6 Règles d'Association (Apriori)

L'algorithmeAprioriaidentifiéplusieursrèglesd'associationsignificativesaprès discrétisation des variables.

**Tab. 7 :** Principales règles d'association découvertes

| Règle | Support | Confiance | Lift |
|---|---|---|---|
| Perf_2sem_High, Frais_OK ⇒ Graduate | 0.28 | 0.89 | 1.78 |
| Perf_1sem_Low, Non_Boursier ⇒ Dropout | 0.15 | 0.72 | 2.25 |
| Âge_Jeune, Boursier ⇒ Graduate | 0.18 | 0.68 | 1.36 |

**Résultat Clé**

La règle la plus forte associe une **performance élevée au 2e semestre** combinée à des **frais de scolarité à jour** avec le statut de diplômé (confiance 89%, lift 1.78). Ces règles confirment l'importance combinée des facteurs académiques et financiers.

## 4. Discussion

### 4.1 Identification du Meilleur Modèle

**Résumé**

La **Random Forest** s'impose comme le modèle le plus performant pour ce problème de classification multi-classe. Elle combine une accuracy supérieure (77%), une excellente stabilité en validation croisée, et une résistance au surapprentissage grâce à l'effet de bagging.

L'analyse de l'importance des variables par Random Forest confirme le rôle prépondérant des indicateurs de performance académique du premier semestre, offrant une fenêtre d'intervention précoce pour les dispositifs d'accompagnement.

## 4.2 Analyse du Compromis Biais-Variance

**Tab. 8 :** Analyse biais-variance des modèles

| Modèle | Biais | Variance | Comportement |
|---|---|---|---|
| **KNN** | Moyen | Élevée | Sensible aux outliers |
| **Arbre de Décision** | Faible | Élevée | Tendance au surapprentissage |
| **Random Forest** | Faible | Faible | Équilibre optimal |
| **Régression Linéaire** | Élevé | Faible | Sous-ajustement possible |

## 4.3 Limites du Dataset

Plusieurs limitations ont été identifiées :

- **Déséquilibre des classes** : la classe "Enrolled" (18%) est sous-représentée
- **Contexte géographique** : données d'un seul établissement portugais, généralisation limitée
- **Absence de données temporelles** : pas de suivi temporel des étudiants

## 4.4 Limites Méthodologiques

**Observation Critique**

La discrétisation requise pour Apriori entraîne une **perte d'information** inhérente. Le choix des seuils de binning influence significativement les règles découvertes et mériterait une analyse de sensibilité.

## 4.5 Difficultés Rencontrées et Solutions

**Tab. 9 :** Difficultés et solutions apportées

| Difficulté | Solution |
|---|---|
| **Déséquilibre de classes** | Stratification lors du split, métriques adaptées (F1, rappel) |
| **Multicolinéarité** | Sélection de variables, régularisation implicite (RF) |
| **Optimisation hyperparamètres** | GridSearchCV avec validation croisée 5fold |
| **Interprétabilité vs Performance** | Analyse de l'importance des variables, visualisation d'arbres |

# 5. Conclusion

## 5.1 Synthèse des Résultats

Ce projet a permis de développer un système complet de prédiction du parcours étudiant, combinant approches supervisées et non supervisées.

**Résultat Clé**

**Résultats majeurs:**

- Random Forest : meilleur modèle avec 77% d'accuracy
- Variables clés : performance 1er semestre, statut financier, âge
- Régression linéaire : $R^2 = 0.73$ pour prédiction des notes
- K-Means : 3 clusters cohérents avec structure naturelle des données
- Apriori : règles actionables liant performance et facteurs socio-économiques

## 5.2 Enseignements Principaux

L'analyse révèle que le **premier semestre est décisif** : les performances académiques initiales sont le prédicteur le plus puissant du parcours futur. Les facteurs financiers (frais de scolarité, bourses) jouent également un rôle significatif, suggérant l'importance des dispositifs d'aide financière.

## 5.3 Recommandations

Sur la base des résultats obtenus, plusieurs recommandations peuvent être formulées :

1. **Système d'alerte précoce** : identifier les étudiants à risque dès la fin du 1er semestre
2. **Accompagnement ciblé** : tutorat renforcé pour les profils détectés
3. **Suivi financier** : vigilance particulière sur le statut des frais de scolarité
4. **Bourses d'aide** : impact positif démontré sur la réussite

## 5.4 Perspectives

Plusieurs pistes d'amélioration et d'extension sont envisageables :

- **SVM (Support Vector Machines)** : potentiellement performant pour ce type de classification
- **Réseaux de neurones** : exploration des architectures MLP pour capter des nonlinéarités complexes
- **XGBoost / LightGBM** : méthodes de boosting souvent supérieures aux forêts aléatoires
- **SMOTE** : rééquilibrage des classes pour améliorer la détection des "Enrolled"

**Résumé**

Ce projet démontre la **faisabilité** et la **pertinence** de l'apprentissage automatique pour la prédiction du décrochage étudiant. Les modèles développés, particulièrement la Random Forest, offrent des performances satisfaisantes et des insights actionnables pour les institutions éducatives.